Teste de carga do Nutri-Hub: resultados

Data: 09/11/2026
Ambiente: produção, https://appnutrihub.com.br. Azure App Service B1 (1 vCPU) e PostgreSQL Flexible Server B1ms.
Ferramenta: k6 v1.0. Os scripts estão em `backend/carga/`, e o passo a passo em `backend/carga/README.md`.

Foram feitos dois testes:

Teste	Pergunta	Resultado
1. Carga (RNF-06)	4 nutricionistas e 40 pacientes usando o app ao mesmo tempo continuam com respostas rápidas?	**APROVADO**
2. Limite	Até quantas requisições por segundo o servidor responde bem?	**20 requisições por segundo**

1. Teste de carga

Como foi feito

- **Massa de teste:** 4 consultórios fictícios, cada um com 10 pacientes com plano alimentar ativo. Esse é o tamanho combinado com o professor para esta etapa.
- **Comportamento dos usuários:** cada usuário virtual navega pelo app como uma pessoa, abrindo uma tela, levando de 5 a 15 s para ler e abrindo a próxima.
  - **Nutricionista:** lista de pacientes, ficha, planos, plano, feedbacks, agenda, busca na Tabela TACO, NPS e grade de atendimento.
  - **Paciente:** plano do dia, marca e desmarca uma refeição, contato do nutricionista, consultas, horários livres, NPS e lembrete.
- **Duas fases:**

Fase	Duração	Usuários ao mesmo tempo
Referência (sistema quase vazio)	4 min	1 nutricionista e 4 pacientes
Carga	6 min e 30 s	**4 nutricionistas e 40 pacientes (44 usuários)**

Resultado

```
Teste de carga do Nutri-Hub (RNF-06), uso realista — 2026-11-10T02:09:08.962Z
Alvo: https://appnutrihub.com.br
Carga: 4 nutricionistas e 40 pacientes (10 por consultório), 44 usuários ao mesmo tempo, com 5 a 15 s entre as telas

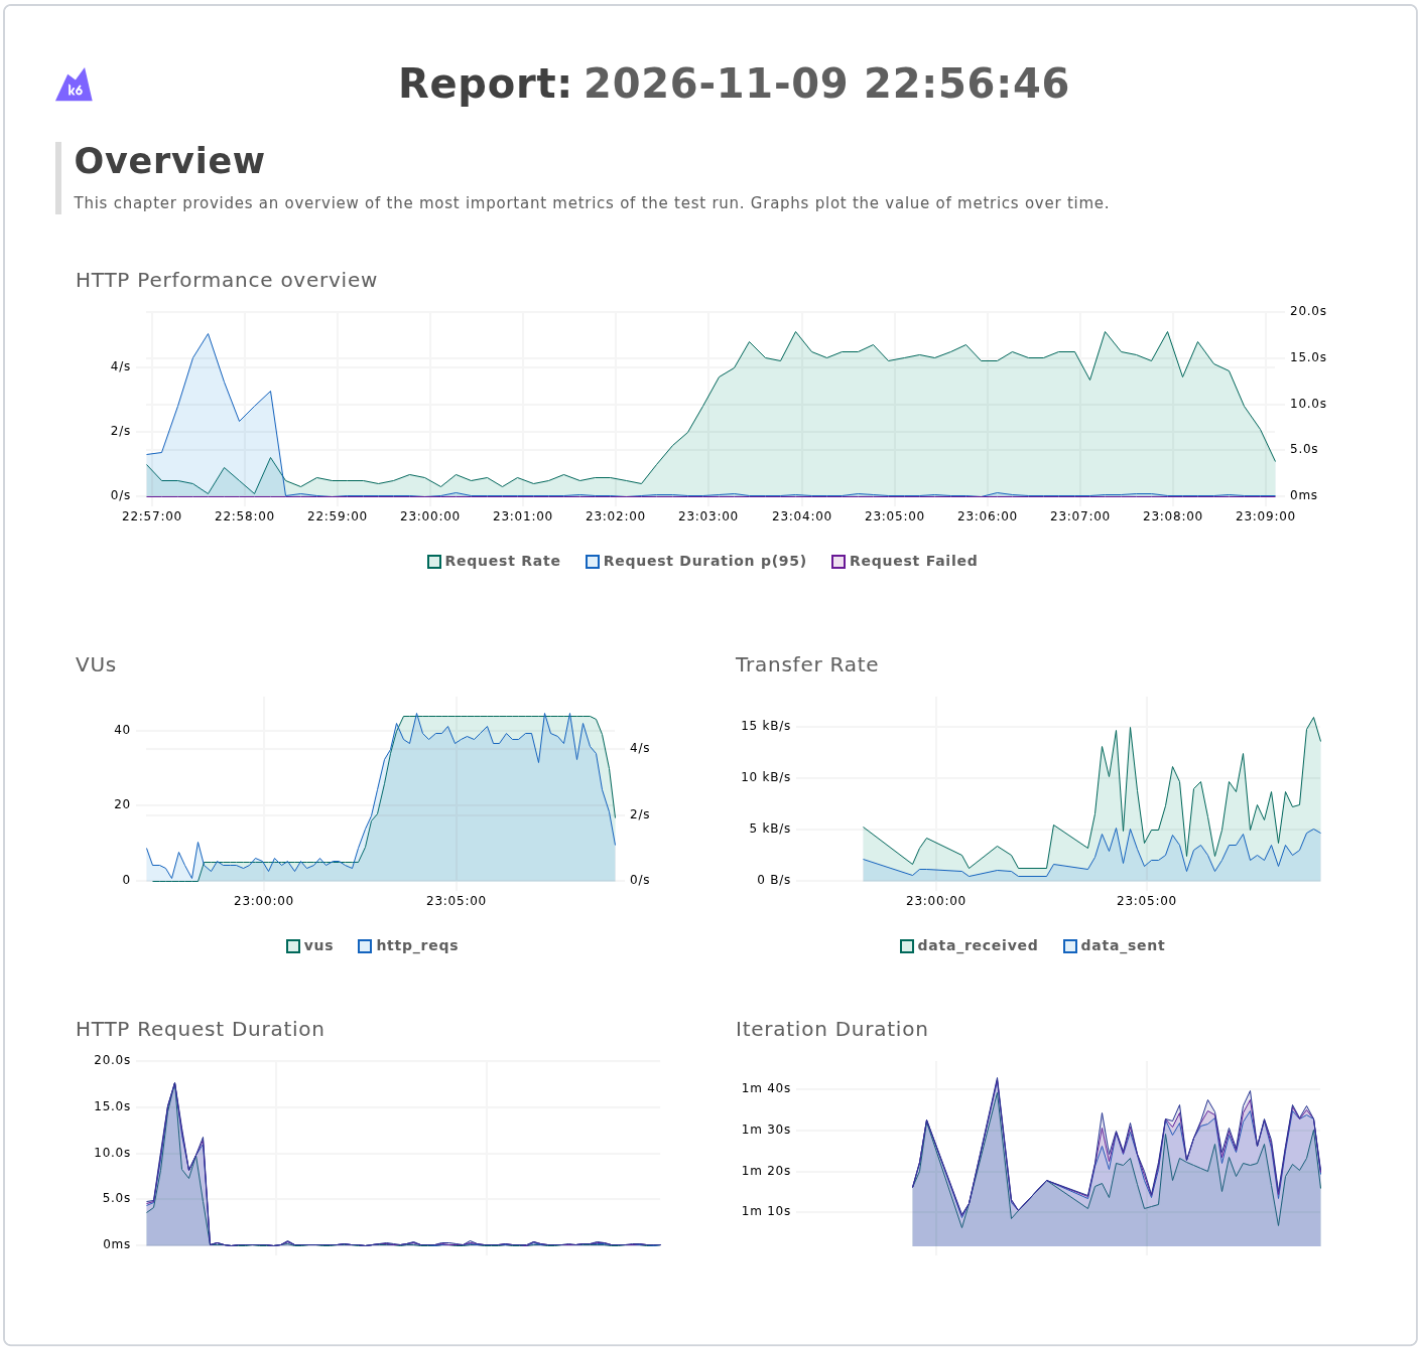
                          Referência (1+4)   Carga
Requisições               141                1612
Requisições por segundo   0.2                2.2
Taxa de erro              0.00%              0.00%
Tempo médio               81 ms              70 ms
Mediana                   49 ms              47 ms
p95                       239 ms             177 ms
p99                       389 ms             306 ms
p95 do plano do paciente  305 ms             266 ms

Critérios:
  [OK] http_req_duration{fase:carga}: p(95)<1000
  [OK] checks{fase:carga}: rate>0.99
  [OK] http_req_failed{fase:carga}: rate<0.01
  [OK] http_req_duration{fase:carga,name:paciente_plano_ativo}: p(95)<2000
  [OK] sem degradação perceptível: p95 subiu -62 ms (0,74x); reprova só acima de 2x e de 200 ms
```

Critério	Meta	Medido	
Taxa de erro	menos de 1%	**0%** (1.612 requisições)	✅
Tempo de resposta (p95)	menos de 1 s	**177 ms**	✅
Abrir o plano do paciente (p95)	menos de 2 s (KPI da seção 1.6 do RFC)	**266 ms**	✅
Degradação em relação ao sistema quase vazio	sem degradação perceptível	**nenhuma**: o p95 foi de 239 ms para 177 ms	✅

Como ler o p95: é o tempo dentro do qual saíram 95% das respostas. Com os 44 usuários, 95% das telas responderam em menos de 0,18 s, e a resposta típica (mediana) levou 47 ms.

Gráficos



- **Request Rate (verde):** as requisições por segundo. É baixa durante a referência e sobe para 4 a 5 por segundo quando os 44 usuários entram, a partir de 23:02.
- **Request Duration p95 (azul):** fica perto de zero durante todo o teste, sem subir com a carga.
- **O pico no começo, até 22:58, não faz parte da medição.** É o login dos 44 usuários, feito antes do teste começar. O login usa bcrypt de custo 12 (RNF-02), que é lento de propósito para dificultar ataques de força bruta. No servidor B1, vários logins ao mesmo tempo disputam a única CPU, e alguns demoram alguns segundos. No uso real, cada pessoa faz login uma vez a cada 8 horas (nutricionista) ou 24 horas (paciente).

2. Teste de limite

Como foi feito

- **A carga sobe em degraus de requisições por segundo:** 2, 4, 6, 8, 10, 15, 20, 25, 30 e 40. Cada degrau dura 1 minuto.
- **Cada requisição é uma tela do app**, sorteada entre as mesmas telas do teste de carga.
- **A capacidade** é o maior degrau em que o servidor atendeu pelo menos 95% das requisições, com p95 abaixo de 1 s e menos de 1% de erro.
- **O teste para sozinho** quando o p95 de um degrau passa de 5 s, para não deixar o site lento mais do que o necessário.

Resultado

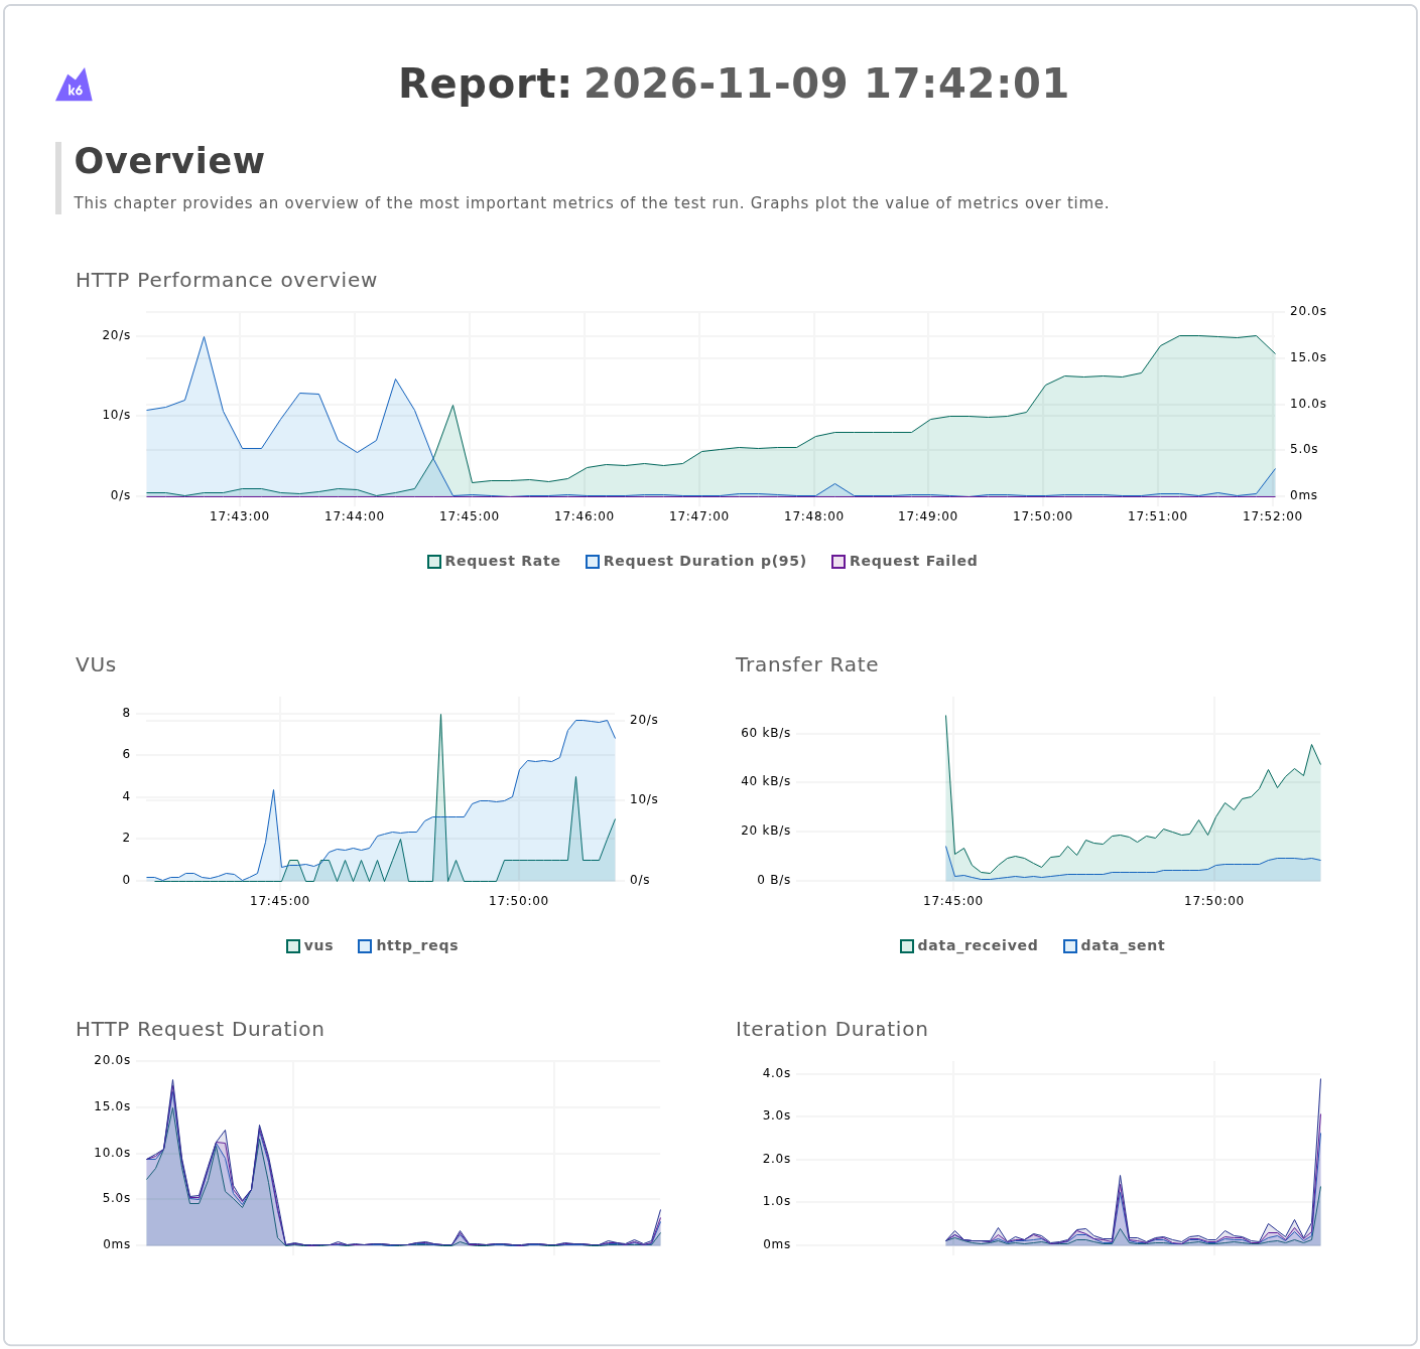
```
Teste de limite do Nutri-Hub — 2026-11-09T20:52:09.203Z
Alvo: https://appnutrihub.com.br

Pedido/s   Atendido/s    Mediana       p95       p99     Erro   Bom?
       2          2.0      47 ms    154 ms    315 ms    0.00%   ok
       4          4.0      46 ms    151 ms    254 ms    0.00%   ok
       6          6.0      78 ms    247 ms    370 ms    0.00%   ok
       8          8.0      47 ms    526 ms   1437 ms    0.00%   ok
      10         10.0      39 ms    141 ms    198 ms    0.00%   ok
      15         15.0      47 ms    160 ms    242 ms    0.00%   ok
      20         20.0      75 ms    288 ms    476 ms    0.00%   ok
      25          2.8    3110 ms   6182 ms   7364 ms    0.00%   NÃO

Capacidade: 20 requisições por segundo com p95 abaixo de 1000 ms e menos de 1% de erro
```

- **Até 20 requisições por segundo,** o servidor atendeu tudo, com p95 abaixo de 300 ms e **0% de erro**.
- **No degrau de 25,** o tempo de resposta subiu para mais de 6 s, e o teste parou ali. Mesmo saturado, o servidor não devolveu erro: as requisições só ficaram lentas.
- **O 526 ms do degrau de 8** é uma oscilação isolada. Os degraus seguintes voltaram para cerca de 150 ms.

Gráficos



- **Request Rate (verde):** os degraus subindo de 17:45 até 17:52.
- **O pico no começo, até 17:45,** é o login antes do teste, fora da medição, como no teste de carga.

Conclusão

1. **Com 4 consultórios e 40 pacientes usando o app ao mesmo tempo, o sistema não degradou:**
    - 0% de erro;
    - 95% das respostas em menos de 0,18 s;
    - o plano do paciente abriu em menos de 0,27 s, bem abaixo da meta de 2 s do RFC.

2. **Esse uso gerou cerca de 4,5 requisições por segundo, e o servidor atual aguenta 20.** Sobra uma margem de mais de 4 vezes.
3. **Quando o servidor satura, o gargalo é a CPU do App Service B1, e não o banco de dados:**
    - num teste anterior, mais pesado, a CPU do App Service chegou a 100%, enquanto a do PostgreSQL ficou em 18%;
    - para mais usuários, a solução é um plano maior da Azure, como o B2, com o dobro de CPU.
4. **O teste também encontrou e ajudou a corrigir um problema real de desempenho:**
    - a verificação do token de login (JWT) gastava um terço da CPU da API;
    - a correção reduziu em cerca de 7 vezes a CPU gasta no tratamento de cada requisição.

Arquivos completos

Os relatórios do k6, com todos os gráficos ao longo do tempo, estão em PDF:

- Teste de carga
- Teste de limite

Ao rodar de novo, o k6 grava os arquivos em `backend/carga/resultados/`, que não é versionado no git:

- `cenario.html` e `limite.html`: os mesmos relatórios, interativos, para abrir no navegador;
- `cenario.txt` e `limite.txt`: as tabelas dos prints acima;
- `cenario.json` e `limite.json`: todos os números.